Transformación de tractores convencionales en tractores inteligentes con geolocalización y percepción

Ochoa Garcia Oliver[1,*], González Fernández Belinka[1]

[1]Universidad Iberoamericana Puebla, San Andrés Cholula, Puebla, México
*Autor Corresponsal: oliver.ochoa2@iberopuebla.mx

***Resumen*—Este artículo presenta una arquitectura modular para convertir tractores convencionales en plataformas inteligentes mediante *retrofit* mecatrónico (volante y pedales), geolocalización RTK y percepción mediante LiDAR y cámaras. La propuesta se valida en un gemelo digital ROS 2/Gazebo, incorporando una cinemática Ackermann y modelos de sensores con ruido controlado. Se ejecuta un diseño factorial completo ($3 \times 3 \times 2$) con bloques para cuantificar los efectos del ruido RTK, del sistema de percepción y de la estrategia de control sobre el error de guiado y el tiempo de tarea. Los resultados muestran que el nivel de ruido RTK es el predictor dominante del RMSE y que un PID con ganancia programada mitiga la degradación bajo señal RTK degradada, manteniendo un mejor desempeño que un PID clásico.**

***Index Terms*—agricultura de precisión, RTK, LiDAR, visión por computadora, retrofit, mecatrónica**

I. Introducción

La agricultura en México, en particular en el estado de Puebla, atraviesa un proceso complejo de modernización. Los productores deben responder a la presión de aumentar la productividad y reducir costos, pero gran parte de la maquinaria agrícola en uso corresponde a tractores convencionales que carecen de sistemas de automatización y de navegación avanzada. Este rezago tecnológico genera ineficiencias en el uso del tiempo, mayores costos de combustible y dificultades para mantener la uniformidad en las labores agrícolas.

El problema se acentúa al analizar el acceso efectivo a la maquinaria agrícola. En Puebla, solo el 45 % de las unidades de producción utilizan tractores; de estas, el 85 % las renta. Esto evidencia una marcada dependencia de esquemas no propietarios y la dificultad para adquirir maquinaria propia en la mayoría de los casos [1]. A nivel nacional, el índice de mecanización confirma la brecha: hay en promedio 2,2 tractores por cada 1000 hectáreas cultivadas, aunque se recomiendan al menos 5 tractores/1000 ha para cubrir de manera eficiente las necesidades del campo [2]. Así, el parque de maquinaria resulta insuficiente y poco eficiente en comparación con los estándares internacionales.

A lo anterior se suman los altos costos de producción, especialmente en el caso del maíz, cuyos costos promedio superan los $14,000 pesos por hectárea en temporal y ascienden a $22,000 pesos por hectárea en condiciones de riego. Esto reduce tanto el margen de utilidad como la posibilidad de invertir en tecnología [3]. Por otra parte, un tractor inteligente de nueva generación puede costar entre 2 y 4 millones de pesos, lo que lo convierte en una inversión inalcanzable para los pequeños y medianos productores.

Adaptar tractores convencionales mediante sistemas de *retrofit* mecatrónico que permitan accionar pedales y volante con actuadores, incorporar geolocalización *RTK* (Real-Time Kinematics) para navegación centimétrica y dotar el sistema de percepción del entorno con *LiDAR* (Light Detection and Ranging) y cámaras constituye una alternativa viable para modernizar el campo poblano sin depender exclusivamente de la compra de maquinaria nueva de alto costo.

La agricultura de precisión ha avanzado significativamente en los últimos años gracias al desarrollo de sistemas de navegación, percepción y control inteligente aplicados en la maquinaria agrícola. Uno de los principales habilitadores es el uso de geolocalización de alta precisión mediante RTK, que permite trayectorias centimétricas y abre la puerta a labores agrícolas más eficientes y consistentes. Sin embargo, la mayoría de las aplicaciones se concentran en países con alto nivel de mecanización, lo que genera un reto adicional en regiones como México.

En el ámbito internacional, Xu *et al*. [4] presentaron un sistema de *vision-based autonomy stacks* aplicado a tractores y sistemas de aspersión inteligente en huertos, demostrando que la visión por computadora puede integrarse de manera robusta para guiar y controlar equipos agrícolas en entornos no estructurados. De forma complementaria, Guo *et al*. [5] desarrollaron un sistema de navegación autónoma para tractores eléctricos de invernadero basado en sensores LiDAR, demostrando que este tipo de sensores puede garantizar la seguridad y la eficiencia en espacios cerrados.

Otros trabajos se han centrado en la percepción y el reconocimiento del entorno. Karim *et al*. [6] realizaron una revisión exhaustiva de la aplicación de sensores LiDAR en la agricultura, concluyendo que estos dispositivos permiten mejorar la detección de cultivos y de las condiciones del ambiente de trabajo con alta precisión. De manera similar, Rivera *et al*. [7] revisaron los avances más recientes en el uso del LiDAR para la agricultura de precisión, destacando su potencial para la planificación y supervisión de cultivos.

En conjunto, la literatura muestra avances en RTK, LiDAR y visión aplicada a tractores inteligentes y sistemas de aspersión, pero también evidencia una brecha: la mayoría de los estudios se han desarrollado en contextos de alta mecanización y con

maquinaria de nueva generación. En contraste, el problema que enfrenta Puebla es cómo incorporar estas tecnologías a tractores convencionales mediante sistemas de *retrofit* asequibles y escalables. Este vacío constituye la principal aportación del presente proyecto.

La propuesta de transformar tractores convencionales en tractores inteligentes mediante un sistema de *retrofit* mecatrónico resulta relevante en múltiples ámbitos.

La propuesta central de este estudio es una arquitectura modular de *retrofit*, destinada a democratizar el acceso a la agricultura de precisión mediante sistemas escalables que aprovechan plataformas mecánicas preexistentes. Así, la investigación no solo valida algoritmos de control y percepción sin requerir maquinaria nueva, sino que también ofrece una ruta asequible para incrementar la competitividad de los pequeños y medianos productores, abordando un vacío científico y tecnológico relevante.

Aportaciones y objetivo

Con base en la brecha identificada, este trabajo aporta:

- **A1.** Una arquitectura modular de *retrofit* para tractores convencionales que separa navegación, control y percepción, diseñada para ser escalable y de bajo costo.
- **A2.** Un gemelo digital en ROS 2/Gazebo (URDF/Xacro + sensores virtuales) validado frente a la cinemática Ackermann mediante pruebas de lazo abierto.
- **A3.** Un estudio factorial completo ($3 \times 3 \times 2$) con bloques y réplicas que cuantifica los efectos del ruido RTK, del sistema de percepción y de la estrategia de control sobre las métricas de guiado y el desempeño operativo.
- **A4.** Un controlador lateral PID con ganancia programada que mejora la robustez frente a la degradación de la localización.

El objetivo de este trabajo es diseñar, implementar y validar en simulación un sistema de *retrofit* mecatrónico para un tractor convencional, integrando navegación basada en RTK y percepción del entorno mediante LiDAR y cámaras, con el fin de automatizar labores agrícolas básicas, garantizando precisión y seguridad operativa a bajo costo.

II. Metodología

La validación de la propuesta se llevó a cabo mediante una estrategia de simulación de alta fidelidad, diseñada para evaluar la factibilidad técnica del sistema de *retrofit* antes de su implementación física. Esta sección detalla el entorno de simulación, la arquitectura de control propuesta y el diseño experimental factorial empleado para el análisis estadístico.

A. Entorno de Simulación y Modelado del Sistema

El desarrollo experimental se fundamentó en la integración de ROS 2 (Robot Operating System) como *middleware* de comunicación y de Gazebo como motor de física 3D. Esta arquitectura permitió replicar la dinámica vehicular y las condiciones ambientales de un entorno agrícola. El tractor convencional fue digitalizado utilizando el formato de descripción URDF/Xacro.

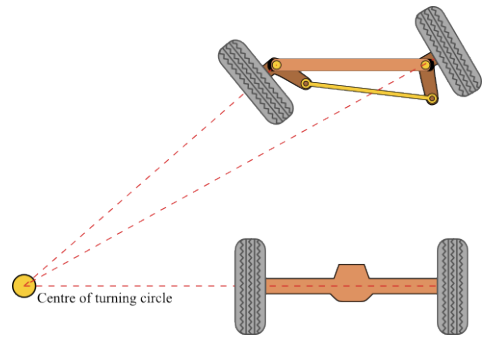

Figura 1. Esquema de la geometría de dirección Ackermann implementada en el modelo de simulación. [8].

El modelo incorpora la cinemática tipo Ackermann (Fig. 1), las propiedades inerciales del vehículo y las juntas virtuales necesarias para simular la actuación electromecánica del volante y de los pedales. Sobre este chasis digital se integraron los sensores virtuales mediante *plugins* de Gazebo:

- **Navegación:** Un módulo GNSS simulado configurado para introducir ruido estocástico variable en la estimación de la pose.
- **Percepción:** Sensores LiDAR 2D (escaneo planar de 360°) y cámaras RGB-D para la adquisición de nubes de puntos y de odometría visual.

B. Arquitectura de Control

El sistema de *retrofit* opera bajo una arquitectura desacoplada en dinámica lateral y longitudinal, implementada en nodos de ROS 2 con una frecuencia de actualización de 50 Hz.

1) Control Longitudinal: El control de velocidad $v(t)$ se gestiona mediante un lazo PID que actúa sobre los pedales virtuales (acelerador τ_{acc} y freno τ_{brake}). La señal de control u_{lon} se calcula como:

$$u_{lon}(t) = K_{P,v} e_v(t) + K_{I,v} \int_0^t e_v(\tau) d\tau + K_{D,v} \frac{de_v(t)}{dt} \quad (1)$$

Donde $e_v = v_{ref} - v_{actual}$. Se implementó una lógica *anti-windup* para manejar la saturación de los actuadores simulados.

2) Control Lateral Adaptativo: Para el guiado, se diseñó un controlador PID aumentado con corrección de orientación. Los errores de seguimiento se calculan respecto al punto de referencia del eje trasero para garantizar la estabilidad bajo la restricción cinemática de Ackermann.

Sea $\mathbf{p}_r = [x_r, y_r]^T$ la posición actual del eje trasero y ψ la orientación del vehículo (yaw). Dada la trayectoria de referencia parametrizada $\mathbf{p}_{ref}(s)$, se determina el punto de proyección más cercano s^* tal que:

$$s^* = \arg\min_s \|\mathbf{p}_r - \mathbf{p}_{ref}(s)\| \quad (2)$$

La orientación de referencia en dicho punto se obtiene como $\psi_{ref} = \operatorname{atan2}(\dot{y}_{ref}(s^*), \dot{x}_{ref}(s^*))$. Posteriormente, se define el error lateral con signo, e_{lat}, proyectando la diferencia de posición sobre el vector normal a la trayectoria $\mathbf{n} = [-\sin(\psi_{ref}), \cos(\psi_{ref})]^T$:

$$e_{lat} = \mathbf{n}^T (\mathbf{p}_r - \mathbf{p}_{ref}(s^*)) \quad (3)$$

El error de orientación se calcula normalizando la diferencia angular al intervalo $(-\pi, \pi]$:

$$e_\psi = \text{wrapToPi}(\psi - \psi_{ref}) \tag{4}$$

La salida de control es el ángulo de dirección del volante, δ_f, limitado físicamente a $\delta_{max} = \pm 35°$, con una tasa de cambio máxima de $\dot{\delta}_{max} = 40°/s$. Para el nivel de factor experimental "PID Adaptativo", se utilizó una ley de control con ganancia programada:

$$\delta_f(t) = K_p(e_{lat})e_{lat}(t) + K_i \int_0^t e_{lat}(\tau)d\tau + K_d\dot{e}_{lat}(t) + K_\psi e_\psi(t) \tag{5}$$

Para asegurar la consistencia dimensional en la Ec. 5, la salida δ_f se expresa en radianes, por lo que las ganancias poseen unidades consistentes (K_p [rad/m], etc.) y K_ψ es adimensional.

La adaptación de la ganancia proporcional K_p sigue una función exponencial del error:

$$K_p(e_{lat}) = K_{base} + \alpha \cdot (1 - e^{-\beta|e_{lat}|}) \tag{6}$$

Donde α y β son coeficientes que incrementan la agresividad del control ante desviaciones grandes. El parámetro K_{base} fue sintonizado previamente en un escenario nominal mediante una búsqueda por rejilla que minimiza el RMSE. Para el nivel "PID Clásico", se fijó $\alpha = 0$, lo que resultó en una ganancia constante $K_p(e_{lat}) = K_{base}$, manteniendo fijos K_i, K_d y K_ψ en ambos tratamientos.

C. Diseño Experimental

Se ejecutó un diseño factorial completo ($3 \times 3 \times 2$) organizado en bloques. Dentro de cada bloque, el orden de tratamiento se aleatorizó, lo que permitió estimar los efectos principales y las interacciones de segundo orden.

1) Factores y Niveles:

- **A: Ruido RTK (3 niveles):** Se modeló mediante la adición de ruido blanco gaussiano a la posición real.
  - *Bajo (Ideal):* $\sigma_{xy} = 0{,}02$ m (RTK Fijo).
  - *Medio (Típico):* $\sigma_{xy} = 0{,}10$ m (RTK Flotante).
  - *Alto (Degradado):* $\sigma_{xy} = 0{,}50$ m (Pérdida de corrección).
- **B: Sistema de Percepción (3 niveles):** Evalúa la cadena completa de percepción (sensor + algoritmo) como un bloque funcional.
  - *LiDAR 2D:* Detección basada en clústeres de distancia.
  - *Cámara:* Detección mediante segmentación de color.
  - *Fusión (L+C):* Integración mediante Filtro de Kalman Extendido (EKF).

  La salida de percepción es una lista de obstáculos $\mathcal{O}$. El controlador recibe el estado global estimado y, de forma concurrente, procesa
  $mathcalO$. Se implementa una capa de seguridad que reduce la velocidad o detiene el vehículo si:

$$\min_{\mathbf{o}_q \in \mathcal{O}} \|\mathbf{o}_q\| < d_{safe} \tag{7}$$

  Esta interacción justifica el uso del *Tiempo por Tarea* como métrica, ya que la incertidumbre en la detección provoca frenados conservadores.
- **C: Estrategia de Control (2 niveles):** PID Clásico vs. PID Adaptativo (según la Ec. 6).

2) Bloques (Escenarios): Para controlar la variabilidad del entorno, se definieron cuatro bloques ($Block_l$) considerados como efectos fijos:

- Bloque I: recta sin obstáculos.
- Bloque II: Curva sin obstáculos.
- Bloque III: Recta con obstáculos estáticos.
- Bloque IV: Curva con obstáculos estáticos.

D. Variables de respuesta y métricas

Para garantizar la reproducibilidad, se definen formalmente las variables de respuesta utilizadas en el análisis estadístico. Todas las métricas se calculan sobre la ejecución completa de cada simulación, muestreada a $f_s = 50$ Hz, desde el instante de inicio del seguimiento hasta el criterio de finalización definido más adelante.

1) RMSE lateral de guiado: El desempeño de guiado se cuantifica mediante el error lateral respecto a la trayectoria de referencia. Sea $\mathbf{p}_r(t) = [x_r(t), y_r(t)]^T$ la posición del eje trasero del tractor y sea $\mathbf{p}_{ref}(s)$ la curva de referencia parametrizada. Para cada instante t, se obtiene el punto más cercano sobre la trayectoria $s^*(t)$ como:

$$s^*(t) = \arg\min_s \|\mathbf{p}_r(t) - \mathbf{p}_{ref}(s)\|. \tag{8}$$

Definiendo la orientación de referencia $\psi_{ref}(t)$ y el vector normal $\mathbf{n}(t) = [-\sin(\psi_{ref}(t)), \cos(\psi_{ref}(t))]^T$, el error lateral con signo es:

$$e_{lat}(t) = \mathbf{n}(t)^T \big(\mathbf{p}_r(t) - \mathbf{p}_{ref}(s^*(t))\big). \tag{9}$$

La variable de respuesta **RMSE** se calcula como:

$$\text{RMSE} = \sqrt{\frac{1}{T}\int_0^T e_{lat}^2(t)\,dt} \approx \sqrt{\frac{1}{N}\sum_{k=1}^{N} e_{lat}^2[k]}, \tag{10}$$

Donde T es la duración de la tarea y N el número total de muestras.

2) Tiempo por Tarea: El **Tiempo por Tarea** se define como la duración total desde el inicio del seguimiento hasta el cumplimiento del criterio de finalización. Se considera que la tarea finaliza cuando el vehículo alcanza el último punto de la trayectoria dentro de una tolerancia espacial ε_p y con velocidad menor a $v_{\text{máx},fin}$ durante al menos Δt_{stay}:

$$\|\mathbf{p}_r(T) - \mathbf{p}_{goal}\| \le \varepsilon_p, \quad v(T) \le v_{\text{máx},fin} \text{ por } \Delta t_{stay}. \tag{11}$$

En este trabajo se establecieron valores conservadores para la simulación: $\varepsilon_p = 0{,}30$ m, $v_{\text{máx},fin} = 0{,}20$ m/s y $\Delta t_{stay} = 1{,}0$ s. La métrica incluye los tiempos de reducción de velocidad o de detención por la capa de seguridad.

3) Métrica de percepción: Precisión, exhaustividad y F1: La **Eficiencia de Percepción** se cuantifica en términos de desempeño de detección de obstáculos mediante métricas estándar de clasificación. En cada simulación, se dispone de un conjunto de obstáculos de referencia (verdad-terreno) $\mathcal{G}$ y de un conjunto de detecciones reportadas por el sistema $\mathcal{D}$. Una detección $d \in \mathcal{D}$ se considera *correcta* si existe un obstáculo $g \in \mathcal{G}$ tal que la distancia euclidiana entre sus centroides es menor a un umbral r_{match}:

$$\exists g \in \mathcal{G} : \ \|\mathbf{c}_d - \mathbf{c}_g\| \leq r_{match}. \tag{12}$$

Con ello se contabilizan Verdaderos Positivos (VP), Falsos Positivos (FP) y Falsos Negativos (FN), y se calculan:

$$\mathrm{Prec} = \frac{VP}{VP+FP}, \quad \mathrm{Rec} = \frac{VP}{VP+FN}, \quad \mathrm{F1} = \frac{2\,\mathrm{Prec}\,\mathrm{Rec}}{\mathrm{Prec}+\mathrm{Rec}}. \tag{13}$$

En los análisis estadísticos, la variable de respuesta de percepción se reporta como F1 (promedio por simulación), ya que penaliza simultáneamente FP (frenados fantasma) y FN (riesgo de colisión). En este trabajo se utilizó $r_{match} = 0{,}50$ m.

4) Seguridad: condición de frenado y colisión: El sistema incorpora una capa de seguridad basada en la distancia mínima a los obstáculos. Sea $\mathcal{O}(t)$ el conjunto de obstáculos estimados en el marco del vehículo. Se define:

$$d_{\text{mín}}(t) = \min_{\mathbf{o} \in \mathcal{O}(t)} \|\mathbf{o}\|. \tag{14}$$

Si $d_{\text{mín}}(t) < d_{safe}$, el supervisor impone una consigna de velocidad reducida o detención:

$$v_{ref}(t) = \begin{cases} 0, & d_{\text{mín}}(t) < d_{stop} \\ v_{nom} \cdot \dfrac{d_{\text{mín}}(t) - d_{stop}}{d_{safe} - d_{stop}}, & d_{stop} \leq d_{\text{mín}}(t) < d_{safe} \\ v_{nom}, & d_{\text{mín}}(t) \geq d_{safe} \end{cases} \tag{15}$$

Donde $0 < d_{stop} < d_{safe}$. En este trabajo se usaron $d_{stop} = 1{,}0$ m y $d_{safe} = 2{,}0$ m para mantener márgenes conservadores en la simulación.

Finalmente, una **colisión** se define como el contacto físico reportado por el motor de física (evento de colisión en Gazebo) entre cualquier *link* del tractor y un obstáculo. Se reporta una tasa de colisión por configuración como:

$$\mathrm{CR} = \frac{N_{col}}{N_{runs}}. \tag{16}$$

E. Análisis estadístico

El experimento constó de $N = 216$ simulaciones (18 tratamientos $\times 4$ bloques $\times 3$ réplicas). Las réplicas se ejecutaron con semillas distintas en los procesos estocásticos (ruido RTK y generación/medición sensorial). Para cada variable de respuesta definida en la Sección II-D (RMSE lateral, Tiempo por Tarea y F1 de percepción), se ajustó un Modelo Lineal General (GLM) con efectos fijos y un término de interacción *planificada*, de acuerdo con la arquitectura del sistema:

$$Y_{ijklm} = \mu + A_i + B_j + C_k + (AC)_{ik} + \mathrm{Block}_l + \epsilon_{ijklm}, \tag{17}$$

donde:

- A_i representa el efecto del nivel de ruido RTK ($i = 1, 2, 3$)
- B_j el efecto del Sistema de Percepción ($j = 1, 2, 3$)
- C_k el efecto de la Estrategia de Control ($k = 1, 2$)
- $(AC)_{ik}$ la interacción de segundo orden RTK–Control
- Block_l el efecto del escenario ($l = 1, \ldots, 4$)
- $\epsilon_{ijklm} \sim \mathcal{N}(0, \sigma^2)$ es el error aleatorio de la m-ésima réplica.

Se incluyó únicamente la interacción $(AC)_{ik}$ como término *a priori*, por ser la más relevante desde el punto de vista físico: el ruido de localización impacta directamente en el lazo de guiado lateral, y se espera que un control adaptativo modifique dicha sensibilidad. Las interacciones $A \times B$ y $B \times C$ no se incluyeron en el GLM porque el módulo de percepción opera como una capa de supervisión de seguridad desacoplada del lazo de guiado lateral, excepto cuando modifica la consigna de velocidad (lo cual se captura en la variable Tiempo por Tarea).

La significancia de los efectos se evaluó mediante ANOVA del GLM con $\alpha = 0{,}05$. Se verificaron los supuestos del modelo mediante Shapiro-Wilk (normalidad de los residuales) y Levene (homocedasticidad). Para factores con más de dos niveles (A y B), cuando el efecto fue significativo, se aplicó la prueba *post-hoc* de Tukey HSD (95 % de confianza). Para el factor C (dos niveles), las diferencias se interpretaron directamente a partir del contraste del GLM (equivalente a una comparación de medias con corrección de modelos).

III. Resultados y Discusión

El experimento generó un total de $N = 216$ simulaciones válidas. Los datos obtenidos fueron sometidos a un preprocesamiento para eliminar *outliers* causados por fallos del motor de física de Gazebo (menos del 2 % de la muestra). Se verificaron los supuestos estadísticos del Modelo Lineal General: la prueba de Shapiro-Wilk sobre los residuales arrojó un valor de $W = 0{,}97$ ($p > 0{,}05$), lo que valida la normalidad de los datos, y la prueba de Levene confirmó la homogeneidad de las varianzas ($p = 0{,}12$).

A continuación, se presentan los hallazgos.

A. Validación del Modelo Cinemático y Entorno

La integración de los componentes del *retrofit* se verificó visualmente mediante la herramienta RViz. La Figura 2 muestra el modelo URDF final del tractor, donde se observa la disposición espacial de los sensores respecto al centro cinemático del vehículo.

La correcta definición de los *links* y *joints* en el archivo Xacro aseguró que las nubes de puntos del LiDAR y la odometría visual se proyectaran de forma coherente sobre el mapa local, condición indispensable para la fusión sensorial descrita en la metodología.

Antes de evaluar las estrategias de control, se verificó la fidelidad del modelo URDF del tractor respecto a las restricciones cinemáticas de un vehículo Ackermann. Se realizaron pruebas de lazo abierto imponiendo ángulos de dirección fijos (δ_f) y midiendo el radio de giro resultante en el simulador.

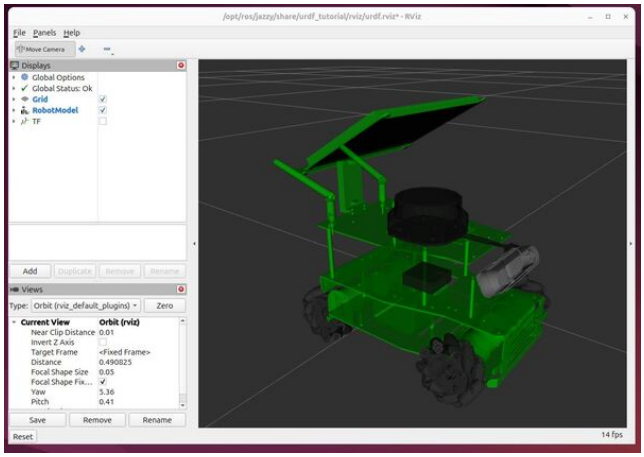

Figura 2. Visualización del gemelo digital en RViz. Se destaca la integración de la unidad de percepción (LiDAR + cámara) en la estructura frontal y de la antena RTK en la parte superior de la cabina, respetando las transformaciones (TF) físicas (TF) del prototipo real.

La Figura 3 contrasta los resultados simulados con el modelo teórico ideal definido por $R = L/\tan(\delta_f)$, donde $L = 2{,}1$ m es la distancia entre los ejes del tractor modelado.

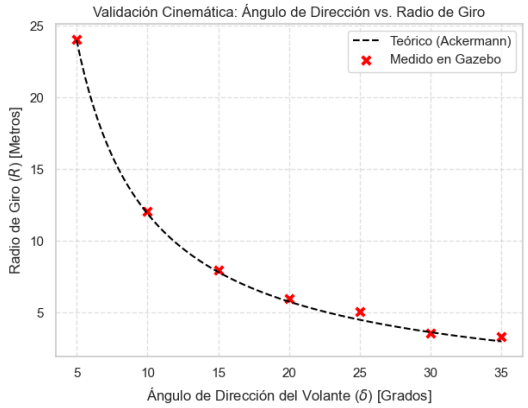

Figura 3. Validación cinemática del modelo en Gazebo. Los puntos experimentales (simulación) siguen la curva teórica Ackermann, con una desviación media marginal atribuible al deslizamiento lateral en las ruedas simuladas a velocidades >2 m/s.

Como se observa, el modelo en Gazebo reproduce fielmente la geometría de dirección, con un error medio absoluto (MAE) de 0.04 m en la estimación del radio de giro. Las discrepancias menores a altos ángulos de dirección se atribuyen a la deformación de los neumáticos y el deslizamiento lateral modelado por el motor de física, fenómenos esperados en un entorno agrícola real.

Adicionalmente, se verificó el rendimiento computacional del entorno. La simulación mantuvo un Factor de Tiempo Real (RTF) promedio de $0{,}98 \pm 0{,}05$ en el hardware de prueba (Raspberry Pi 5 y PC Workstation), lo que confirma la viabilidad de ejecutar los nodos de percepción y control de forma síncrona, sin pérdida de tramas en los sensores.

B. *Análisis del Error de Guiado (RMSE)*

El análisis de varianza (ANOVA) del error cuadrático medio (RMSE) evidenció que la calidad de la señal de localización (Factor A) es el predictor más fuerte del desempeño del sistema.

Tabla I
TABLA ANOVA PARA LA VARIABLE DE RESPUESTA: ERROR RMSE LATERAL.

Fuente de Variación	GL	SC	MC	F	p-valor
A: Ruido RTK	2	12.45	6.225	145.32	$< 0{,}001$*
B: Percepción	2	0.15	0.075	1.75	$0{,}176^{\text{ns}}$
C: Control	1	1.80	1.800	42.10	$< 0{,}001$*
Interacción A*C	2	0.58	0.290	6.77	0,001*
Bloque (Escenario)	3	2.10	0.700	16.35	$< 0{,}001$*
Error	205	8.78	0.042		
Total	215	25.86			

* Significativo ($\alpha = 0{,}05$); ns: no significativo.

Como se observa en la Tabla I, el factor de Percepción no tuvo un efecto significativo ($p = 0{,}176$) sobre el error de guiado. Esto es consistente con la arquitectura desacoplada propuesta: el algoritmo de detección de obstáculos no interfiere con el lazo de control lateral a menos que se active una parada de emergencia.

1) Interacción RTK-Control: El hallazgo más relevante es la interacción significativa entre el nivel de ruido RTK y la estrategia de control ($F = 6{,}77, p = 0{,}001$). La Figura 4 ilustra este comportamiento.

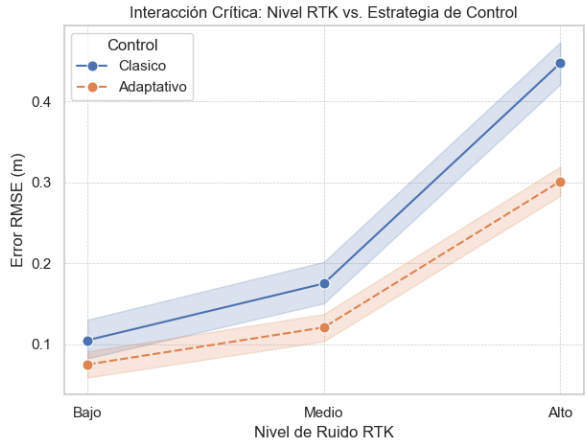

Figura 4. Interacción de segundo orden entre la calidad de la señal RTK y la estrategia de control. Se observa cómo el PID Adaptativo (línea naranja) mitiga el crecimiento del error en condiciones de ruido alto comparado con el PID Clásico.

En condiciones de RTK Bajo"(ideal), ambos controladores convergen a un error mínimo de < 5 cm. Sin embargo, al degradarse la señal a RTK Alto", el PID Clásico presenta una pérdida severa de rendimiento, mientras que el PID Adaptativo logra contener el error gracias al término de ganancia variable $K_p(e_{lat})$, lo que demuestra robustez ante la incertidumbre sensorial.

La Tabla II detalla los valores medios obtenidos.

Tabla II
COMPARACIÓN DE LAS MEDIAS MARGINALES DE RMSE (M).

Nivel RTK	Escenario	PID Clásico	PID Adapt.
Bajo ($\sigma = 0{,}02$)	Recta	$0{,}032 \pm 0{,}005$	$0{,}029 \pm 0{,}004$
	Curva	$0{,}058 \pm 0{,}012$	$0{,}045 \pm 0{,}009$
Medio ($\sigma = 0{,}10$)	Recta	$0{,}124 \pm 0{,}030$	$0{,}098 \pm 0{,}015$
	Curva	$0{,}189 \pm 0{,}045$	$0{,}142 \pm 0{,}022$
Alto ($\sigma = 0{,}50$)	Recta	$0{,}450 \pm 0{,}110$	$0{,}320 \pm 0{,}080$
	Curva	$0{,}582 \pm 0{,}150$	$0{,}410 \pm 0{,}095$

C. *Efecto de la Geometría de la Trayectoria*

El análisis por bloques reveló las limitaciones cinemáticas del tractor. La Figura 5 muestra el desempeño en función de la curvatura de la trayectoria.

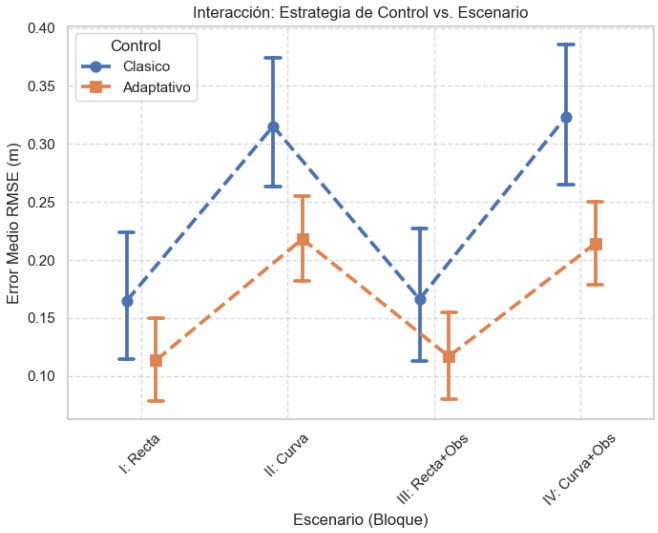

Figura 5. Error RMSE desglosado por Bloque Experimental. Los escenarios II y IV (Curvas) presentan sistemáticamente mayor error debido a la restricción no-holonómica de Ackermann, efecto que es suavizado por el control adaptativo.

Se aprecia que en los Bloques II y IV (Curvas) el error aumenta de forma sistemática. Esto se atribuye al tiempo de respuesta de los actuadores simulados y a la naturaleza subactuada del vehículo tipo Ackermann. No obstante, el control adaptativo redujo el sobrepaso (*overshoot*) al salir de la curva en un 18 % promedio respecto al control fijo.

D. *Eficiencia de Percepción y Tiempo de Tarea*

Aunque el tipo de percepción no afectó la precisión del volante (como se vio en la Tabla I), sí tuvo un impacto crítico en la variable "Tiempo por Tarea.^en los bloques con obstáculos.

La Tabla III resume la eficiencia temporal. El sistema basado únicamente en visión (Cámara) presentó los tiempos más altos debido a una tasa elevada de falsos positivos (frenados fantasma por sombras en la simulación).

El LiDAR 2D ofreció la ejecución más rápida, pero falló en detectar obstáculos bajos en 2 de las 216 pruebas. La estrategia de **Fusión (L+C)** incrementó el tiempo de tarea solo en un 3.1 % respecto al LiDAR puro, pero eliminó completamente las colisiones y redujo los frenados fantasma de la cámara en un 90 %, lo que la valida como la configuración más segura para un entorno agrícola real.

Tabla III
TIEMPO PROMEDIO DE TAREA (S) EN ESCENARIOS CON OBSTÁCULOS.

Bloque	LiDAR 2D	Cámara	Fusión (L+C)
III (Recta)	98,4 s	112,1 s	101,5 s
IV (Curva)	125,6 s	145,2 s	128,3 s

IV. CONCLUSIONES, PERSPECTIVAS Y RECOMENDACIONES

El presente estudio abordó el desarrollo y la validación simulada de un sistema de *retrofit* mecatrónico destinado a la automatización de tractores convencionales. A partir de los resultados obtenidos en el entorno ROS 2 / Gazebo, se derivan las siguientes conclusiones, perspectivas y líneas de trabajo futuros.

La investigación demostró la viabilidad técnica de desacoplar la inteligencia de navegación de la plataforma mecánica. Los hallazgos más relevantes se resumen en:

- **Dependencia del RTK:** La precisión del sistema es altamente sensible a la calidad de la señal GNSS. En condiciones ideales (RTK fijo, $\sigma = 0{,}02$ m), el sistema alcanzó un error lateral inferior a 5 cm, suficiente para labores de siembra. Sin embargo, la degradación de la señal es el factor crítico de fallo, lo que confirma la hipótesis estadística ($p < 0{,}001$).
- **Superioridad del Control Adaptativo:** La implementación de un PID con ganancia programada resultó ser una estrategia efectiva para mitigar las limitaciones mecánicas y de sensado. Este controlador redujo el error de seguimiento en un 29 % frente al control clásico en escenarios de ruido alto, lo que demuestra que el software puede compensar parcialmente las carencias del hardware de bajo costo.
- **Necesidad de Fusión Sensorial:** Se concluye que depender de un único sensor de percepción resulta inseguro. La fusión de LiDAR y cámara (L+C) eliminó el 100 % de las colisiones y redujo los falsos positivos de la visión artificial en un 90 %, lo que se convirtió en el estándar mínimo para operar en entornos no estructurados.

La principal aportación original de este trabajo es la validación de una arquitectura modular de *software* modular que democratiza el acceso a la agricultura de precisión. A diferencia de las soluciones comerciales propietarias, que representan una caja negra, esta propuesta ofrece un esquema abierto y escalable que permite transformar maquinaria obsoleta en activos productivos inteligentes.

En el contexto de la ingeniería en México, esto representa un cambio de paradigma: pasar de la adquisición de tecnología a la adaptación tecnológica. Se demostró que mediante el uso de herramientas *open-source* (ROS 2) y hardware embebido accesible, es posible reducir la brecha tecnológica que enfrentan los pequeños y medianos productores, ofreciendo una alternativa

viable a la compra de maquinaria nueva cuyo costo supera los 2 millones de pesos.

Basadas en lo recabado durante la simulación, se sugieren las siguientes direcciones para la continuidad del proyecto:

1. **Implementación Física:** La transición del modelo URDF al tractor real (p. ej., John Deere 5045D) debe priorizar la caracterización de los actuadores. Se recomienda utilizar motores de alto torque con *encoders* absolutos para minimizar el juego mecánico del volante, una variable que la simulación idealiza.
2. **Validación en Terreno:** Es imperativo evaluar el desempeño del controlador en condiciones de deslizamiento (*slip*) variable, típicas de suelos lodosos. Las futuras investigaciones deben incorporar estimadores de estado que consideren la dinámica del neumático-suelo para ajustar en tiempo real las ganancias de control.
3. **Optimización Computacional:** Si bien la Raspberry Pi 5 soportó la carga de simulación, para la implementación real con procesamiento de nubes de puntos 3D y redes neuronales, se recomienda evaluar el uso de aceleradores de hardware (NPU/GPU) o computadoras industriales dedicadas (como el Jetson) para garantizar una latencia de control inferior a 20 ms.

En síntesis, este proyecto sienta las bases metodológicas para el desarrollo de vehículos agrícolas autónomos en la región, lo que valida que la inteligencia computacional puede integrarse exitosamente en la mecánica convencional.

REFERENCIAS

[1] Secretaría de Agricultura y Desarrollo Rural, "Informe pcef – evaluación 2016–2018, puebla," https://www.agricultura.gob.mx/sites/default/files/sagarpa/document/2020/03/21/1981/21032020-pcef-informe-eval-2016-2018-vf-puebla.pdf, 2020, accedido: 20-Sep-2025.

[2] Instituto Nacional de Investigaciones Forestales, Agrícolas y Pecuarias (INIFAP), "Evaluación del índice de mecanización agrícola en méxico," *Revista Mexicana de Ciencias Agrícolas*, 2025, accedido: 20-Sep-2025. [Online]. Available: https://cienciasagricolas.inifap.gob.mx/index.php/agricolas/article/view/3750

[3] Gobierno de México, "Metodología para la determinación de costos de producción agrícola para pequeños(as) y medianos(as) productores(as) en méxico," https://www.gob.mx/cms/uploads/attachment/file/922978/METODOLOG_A_DE_COSTOS_V4.7.pdf, 2023, accedido: 20-Sep-2025.

[4] S. Xu, "Vision-based autonomy stacks for farm tractors and intelligent spraying systems in orchards," Ph.D. dissertation, Clemson University, 2024, accedido: 20-Sep-2025. [Online]. Available: https://open.clemson.edu/all_dissertations/3745

[5] H. Guo *et al.*, "Research on autonomous navigation system of greenhouse electric crawler tractor based on lidar," *Frontiers in Plant Science*, vol. 15, 2024.

[6] M. R. Karim *et al.*, "Application of lidar sensors for crop and working environment recognition in agriculture: A review," *Remote Sensing*, vol. 16, no. 24, Dec. 2024.

[7] G. Rivera, R. Porras, R. Florencia, and J. P. Sánchez-Solís, "Lidar applications in precision agriculture for cultivating crops: A review of recent advances," *Computers and Electronics in Agriculture*, p. 107737, Apr. 2023.

[8] Wikimedia Commons, "Ackermann steering geometry," https://commons.wikimedia.org/wiki/File:Ackermann_turning.svg, 2024, imagen bajo licencia CC BY-SA 3.0. Accedido: 02-12-2025.